Jianwei Yang (杨建伟)

Microsoft Research · xAI

AI代理 多模态

职位: 原MSR首席研究员，现xAI技术团队
获奖: CVPR 2022 Best Paper Final (GLIP)
代表工作: Magma、GLIP、X-Decoder、SEEM
近作: Phi-3-Vision、Semantic-SAM (ECCV 2024)
论文: openaccess.thecvf.com/content/CVPR2025/papers/Yang_Ma

关键指标

统一 理解+行动	**双环境** 数字+物理
HN第一 热度排名	**Microsoft** 旗舰项目

应用场景

- UI自动化导航与操作
- 物理机器人控制
- 多模态AI代理系统
- 跨环境任务执行

1 CVPR 2025 · Multimodal AI Agent

Magma: A Foundation Model for Multimodal AI Agents

创新点总结

核心贡献： 首个能理解和执行多模态输入的基础模型，同时具备数字环境UI导航和物理环境机器人操作能力。创新包括：(1)保留视觉语言理解能力；(2)添加行动执行能力；(3)数字物理世界无缝切换；(4)支持UI元素定位、机器人操作规划。项目在Hacker News排名第一，代表Microsoft Research在多模态AI代理方向的旗舰工作。

Magma架构：统一理解与行动的多模态AI代理框架

合作建议

Microsoft Research在多模态AI代理方向领先，适合在基础模型、跨环境AI系统方向合作。项目开源(github.com/microsoft/Magma)，社区活跃度高，易于扩展应用。

Moo Jin Kim

Stanford · UC Berkeley

机器人学习 VLA

合作团队: Chelsea Finn (Stanford教授), Sergey Levine (UC Berkeley教授)
研究方向: 机器人学习、视觉语言行动模型
代表工作: OpenVLA、RT-X数据集、Meta-World
开源: github.com/openvla/openvla
论文: arxiv.org/abs/2406.09246

关键指标

+16.5% 超越RT-2-X	**7B** 参数量
完全开源 训练配方	**29任务** 测试场景

应用场景

- 机器人操作控制
- 跨机器人平台部署
- 参数高效微调(LoRA)
- 新机器人快速适配

2 arXiv 2024 · Vision-Language-Action

OpenVLA: An Open-Source Vision-Language-Action Model

创新点总结

核心贡献: 开源7B参数VLA模型，在29个任务上超越RT-2-X (55B) 16.5%，参数量仅1/7。创新包括：(1)基于Prismatic-7B VLM微调；(2)完整的开源训练配方；(3)支持参数高效微调(LoRA)；(4)跨机器人平台泛化能力。首个高性能开源VLA模型，降低了机器人学习门槛。

OpenVLA架构：基于Prismatic VLM的机器人操作模型

合作建议
Stanford/UC Berkeley团队在机器人学习方向资源丰富，适合在机器人部署、数据集构建、真实场景验证上合作。模型完全开源，易于二次开发和定制。

Google DeepMind

Robotics Team

VLA 机器人

核心贡献者: Anthony Brohan, Noah Brown等
研究方向: 视觉语言行动模型、机器人学习
代表工作: RT-1、RT-2、RT-X、SayCan
数据集: RT-X (100万+机器人轨迹)
论文: robotics-transformer2.github.io

关键指标

首个 VLA模型	**55B** 参数规模
涌现能力 推理能力	**6K+** 评估试验

应用场景

- 机器人操作推理
- 零样本任务迁移
- 语言指令执行
- 多机器人平台部署

3 Google DeepMind · Vision-Language-Action

RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control

创新点总结

核心贡献： 首个将视觉语言模型(VLM)转化为视觉语言行动模型(VLA)的工作，直接输出机器人动作。创新包括：(1)VLM预训练+机器人数据联合训练；(2)涌现推理能力（数学推理、符号理解、多语言理解）；(3)基于PaLM-E和PaLI-X两种实现；(4)Web知识迁移到机器人控制。奠基性工作，定义了VLA模型范式。

RT-2架构：视觉语言模型转化为机器人控制系统

合作建议

Google DeepMind在VLA方向奠基性工作，适合在基础研究、大规模数据集(RT-X)上合作。RT-X数据集已开放，包含100万+机器人轨迹，可用于模型训练。

赵

Yuwang Zhao

研究团队

视觉推理 VLA

研究方向: 视觉推理、机器人学习、链式思维

创新点: 将链式思维引入VLA模型

发表: CVPR 2025

应用: 复杂任务规划、多步骤推理

论文: openaccess.thecvf.com/content/CVPR2025/papers/Zhao_Co
VLA

关键指标

链式推理 CoT能力	**视觉** 思维链
多步规划 任务分解	**CVPR** 2025

应用场景

- 复杂操作任务规划
- 多步骤推理执行
- 任务分解与规划
- 推理过程可视化

4 CVPR 2025 · Visual Reasoning

CoT-VLA: Visual Chain-of-Thought Reasoning for Vision-Language-Action Models

创新点总结

核心贡献： 将视觉链式思维(Chain-of-Thought)推理引入VLA模型，显著提升复杂任务的规划与执行能力。创新包括：(1)视觉推理链构建方法；(2)多步骤任务分解机制；(3)推理过程可视化；(4)与现有VLA模型无缝集成。CVPR 2025发表，扩展了VLA模型在复杂场景下的推理深度。

CoT-VLA架构：视觉链式思维推理框架

合作建议

在需要复杂推理的机器人任务上有应用潜力，适合与现有VLA模型(OpenVLA、RT-2)结合，提升复杂任务的执行成功率。

Embodied AI Workshop

CVPR 2026 · 第6届

具身智能 导航操作

主题: 具身智能体的看、说、听、推理、行动
领域: 计算机视觉、语言、图形、机器人
挑战赛: 视觉导航、物体操作、社交交互
仿真平台: Habitat、AI2-THOR、BEHAVIOR
官网: embodied-ai.org

关键指标

第6届 年度会议	**多模态** 感知交互
仿真平台 环境支持	**挑战赛** 基准测试

研究方向

- 视觉导航与探索
- 物体操作与交互
- 人机交互与协作
- 多智能体系统

5 CVPR 2026 Workshop · Embodied AI

6th Embodied AI Workshop: Agents that See, Talk, Listen, Reason, and Act

创新点总结

核心主题: CVPR 2026第6届Embodied AI Workshop，聚焦具身智能体在交互环境中的多模态能力。涵盖视觉导航、物体操作、社交交互等核心挑战，连接计算机视觉、语言、图形和机器人领域。提供标准化仿真平台(Habitat、AI2-THOR)和基准测试，推动具身AI研究发展。

Embodied AI：多模态感知与交互能力框架

合作建议

CVPR官方Workshop，汇聚顶尖研究团队，适合关注具身AI最新进展、参与挑战赛、建立学术合作。提供标准化仿真平台和基准测试，便于算法验证和对比。